Transformer

GROUP 4

Thành viên

Họ và tên	MSSV	Tỷ lệ hoàn thành
Nguyễn Quốc An		
Huỳnh Công Xuân Bảo		
Nguyễn Thị Vân Anh		
Nguyễn Thanh Bình		
Nguyễn Hoàng Đăng		

1. Đặt vấn đề
Vì sao Transformer ra đời?

Hạn chế của RNN/LSTM khi xử lý chuỗi

- RNN xử lý tuần tự nên khó song song hóa.
- Khó ghi nhớ phụ thuộc dài hạn giữa các từ ở xa nhau.
- LSTM cải thiện bộ nhớ nhưng vẫn chưa giải quyết triệt để tính tuần tự.

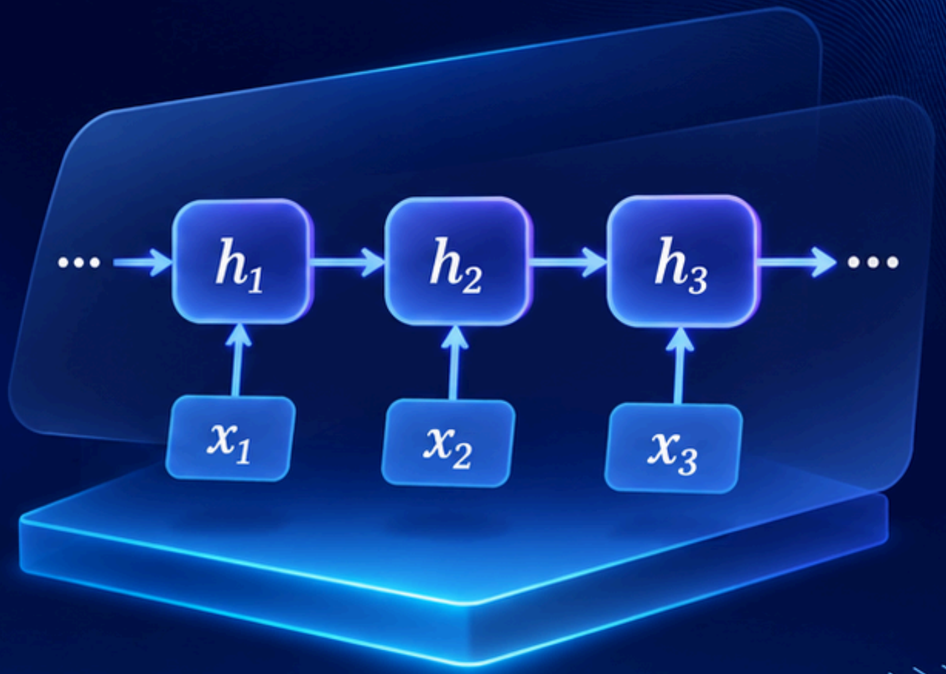

→ **Cần một kiến trúc học ngữ cảnh tốt hơn và hiệu quả hơn.**

2. Giải pháp của Transformer
Self-Attention

Học quan hệ giữa các từ ở xa nhau

- Transformer thay cơ chế hồi quy bằng Self-Attention.
- Mỗi từ có thể liên hệ trực tiếp với các từ khác trong câu.
- Nhờ đó mô hình học ngữ cảnh xa tốt hơn và xử lý hiệu quả hơn.

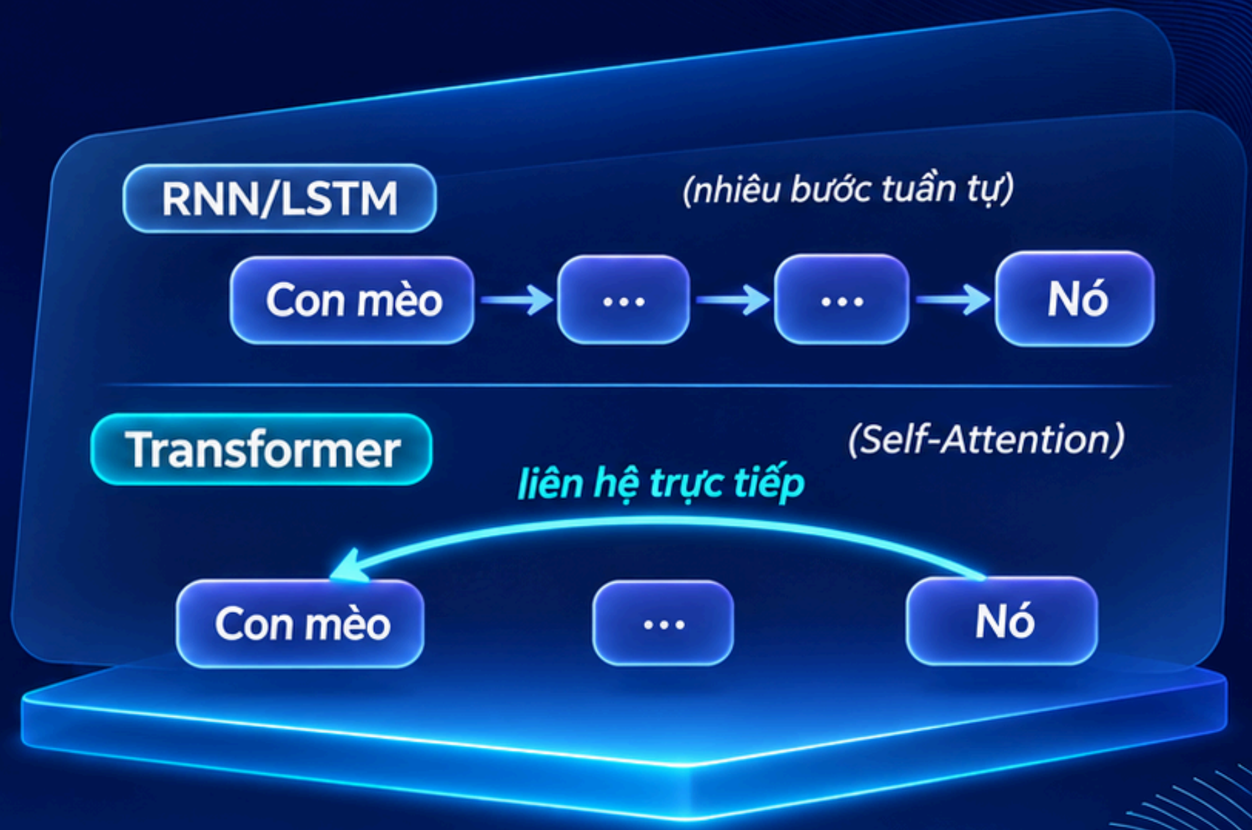

→ **Transformer giải quyết tốt hơn bài toán phụ thuộc dài hạn.**

3. Kiến trúc tổng quan Encoder – Decoder

Các thành phần và luồng dữ liệu trong Transformer

- Encoder mã hóa câu đầu vào thành biểu diễn ngữ cảnh.
- Decoder dùng thông tin từ Encoder để tạo đầu ra.
- Attention là cơ chế cốt lõi giúp mô hình học quan hệ giữa các token.

→ Transformer nguyên bản được xây dựng theo kiến trúc Encoder–Decoder.

4. Biểu diễn đầu vào
Tokenization, Embedding & Positional Encoding

Một câu ngắn được chuyển thành chuỗi vector

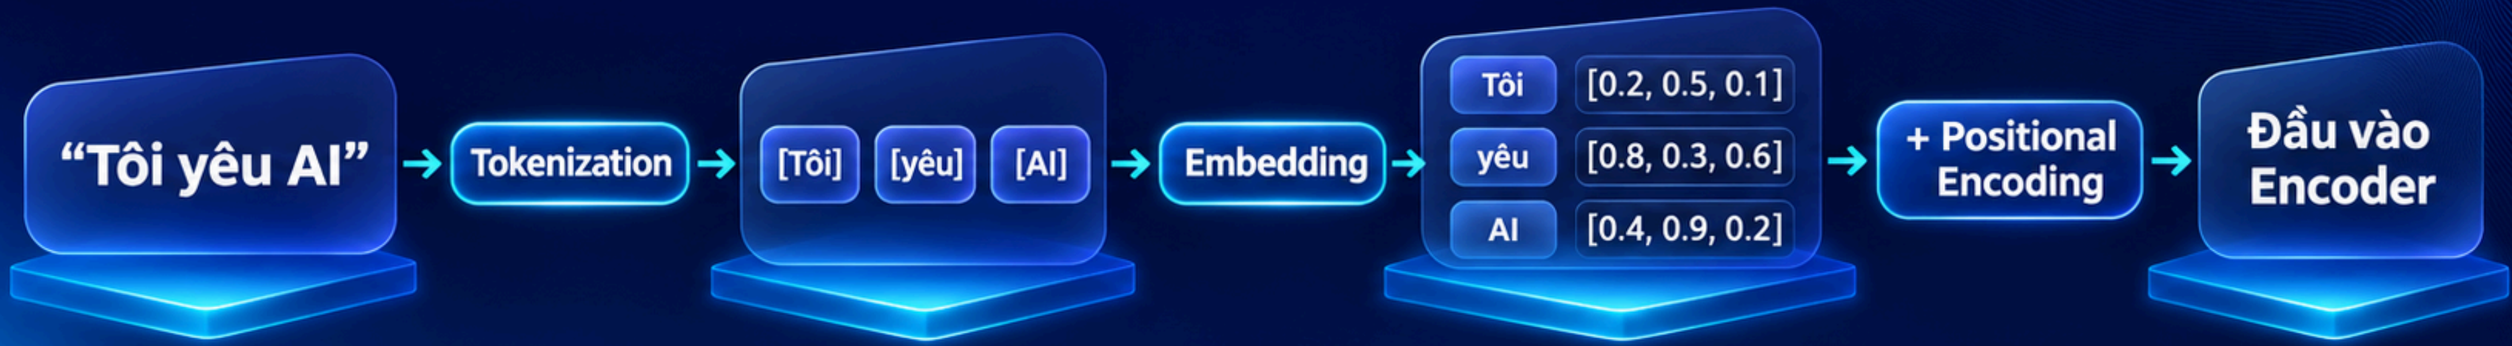

- Tokenization chia câu thành các token.
- Embedding biến mỗi token thành vector số.
- Positional Encoding bổ sung thông tin vị trí cho từng token.

Ví dụ vector (giá trị minh họa)

Tôi	[0.2, 0.5, 0.1]
yêu	[0.8, 0.3, 0.6]
AI	[0.4, 0.9, 0.2]

→ **Văn bản phải được biểu diễn thành vector trước khi đưa vào Transformer.**

self-attention

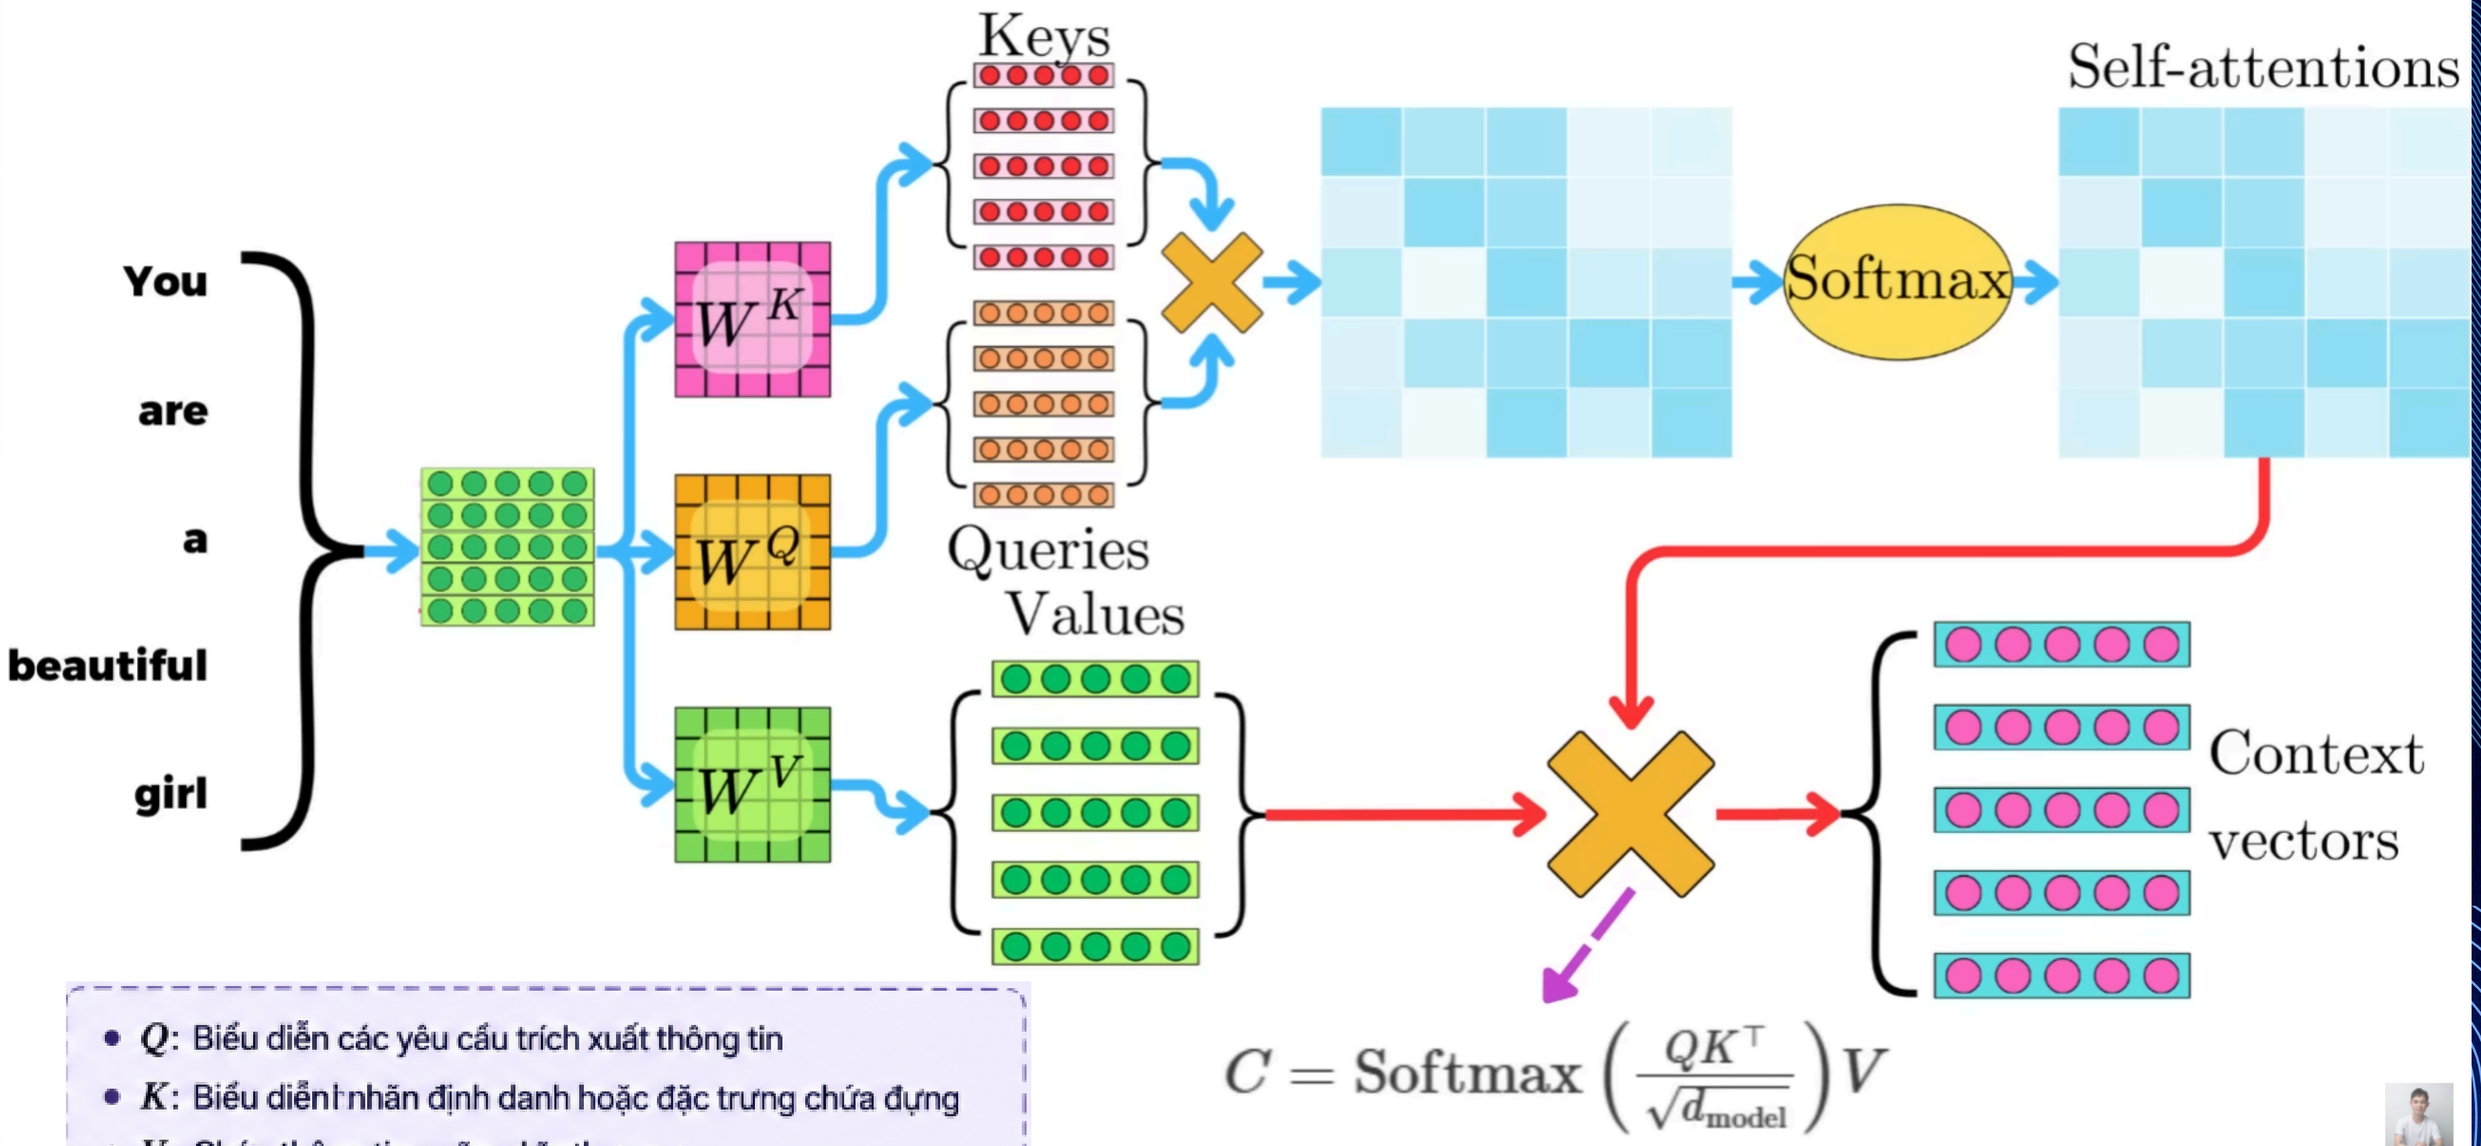

- Q: Biểu diễn các yêu cầu trích xuất thông tin
- K: Biểu diễn nhãn định danh hoặc đặc trưng chứa đựng
- V: Chứa thông tin ngữ nghĩa thực sự

1. SCALED DOT-PRODUCT ATTENTION

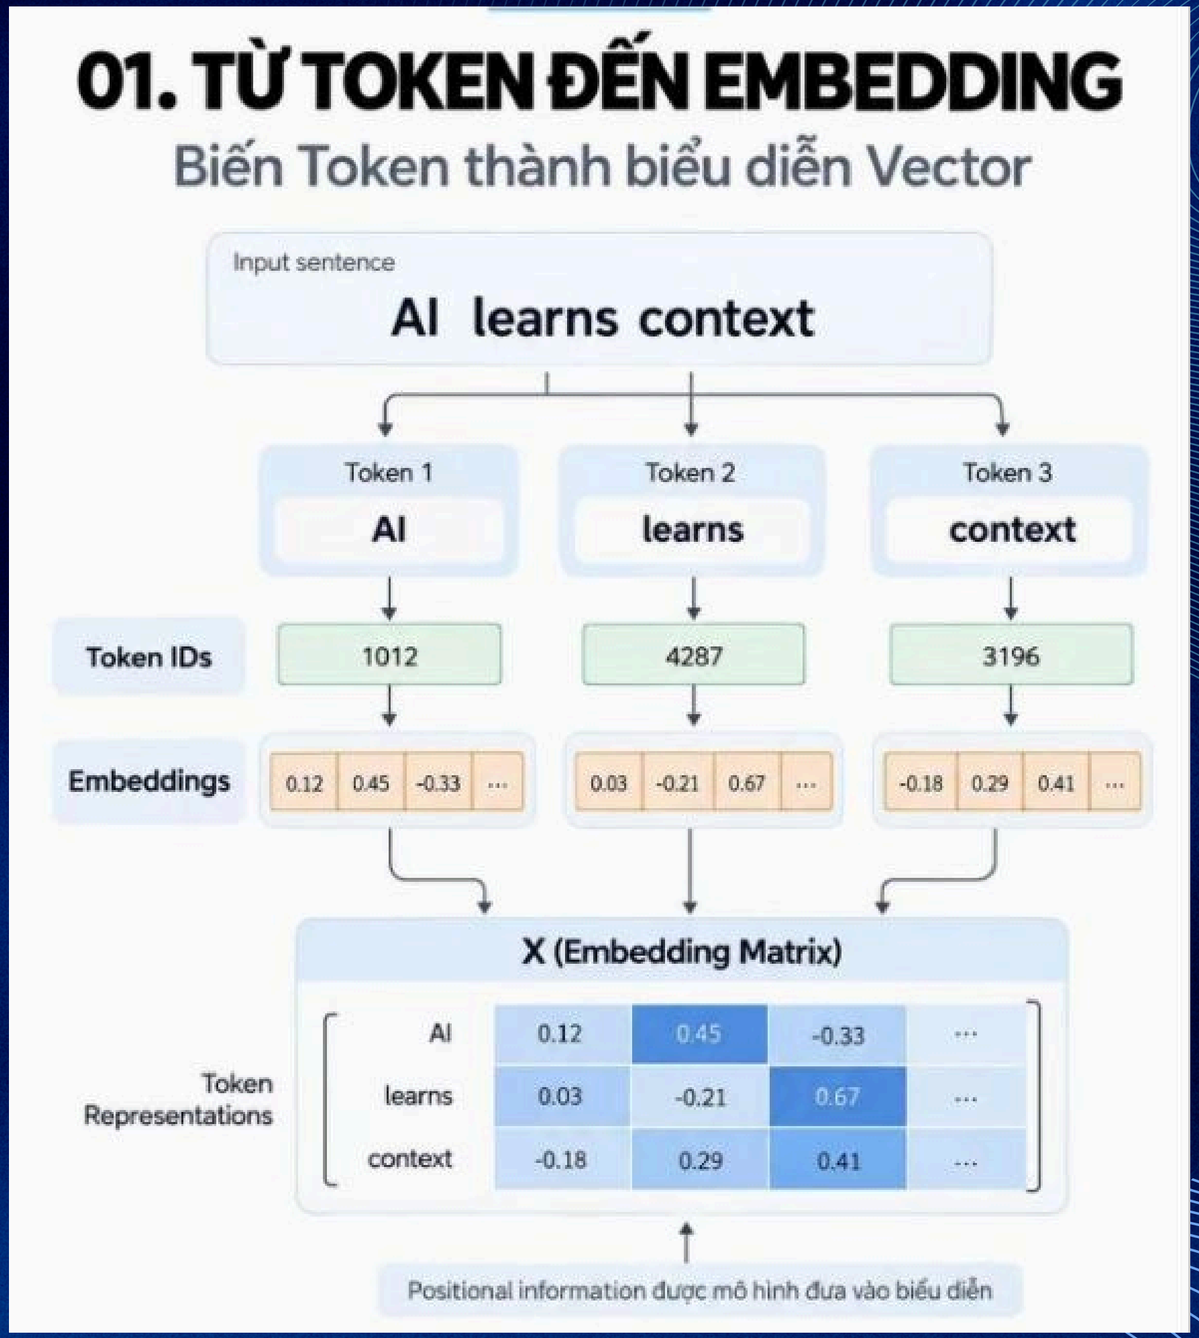

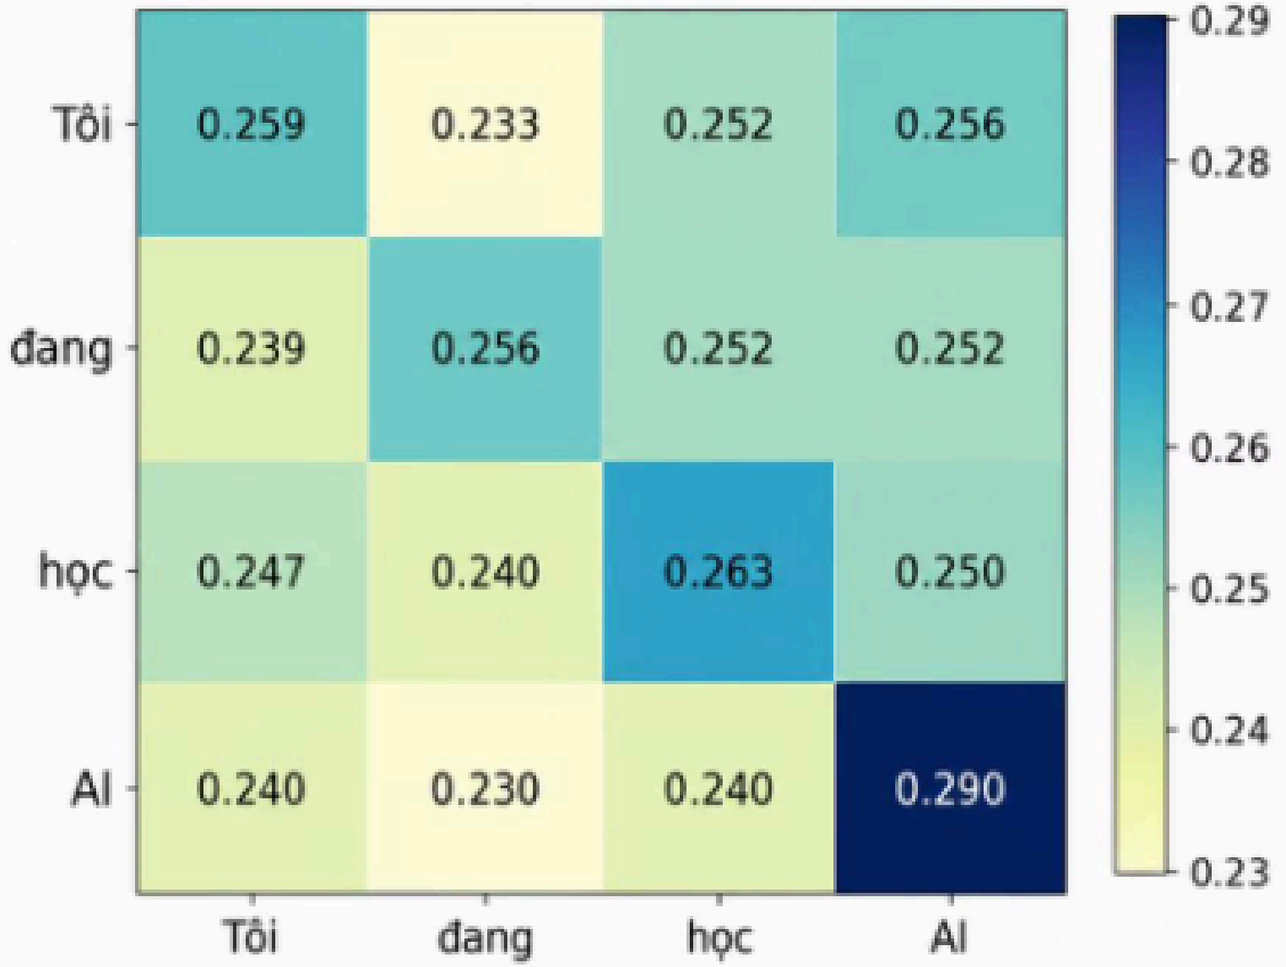

Hình 6.21: Ma trận attention score sau khi đi qua hàm softmax kết hợp với heatmap thể hiện mức độ "chú ý" của một từ lên các từ còn lại trong câu, màu đậm thể hiện trọng số chú ý cao hơn. Cụ thể hơn, hàng của ma trận là các từ truy vấn (Q), cột của ma trận là các từ ngữ cảnh (K).

2. Multi-Head Attention (MHA)

– Nhiều đầu chú ý, nhìn nhận ngữ cảnh đa chiều –

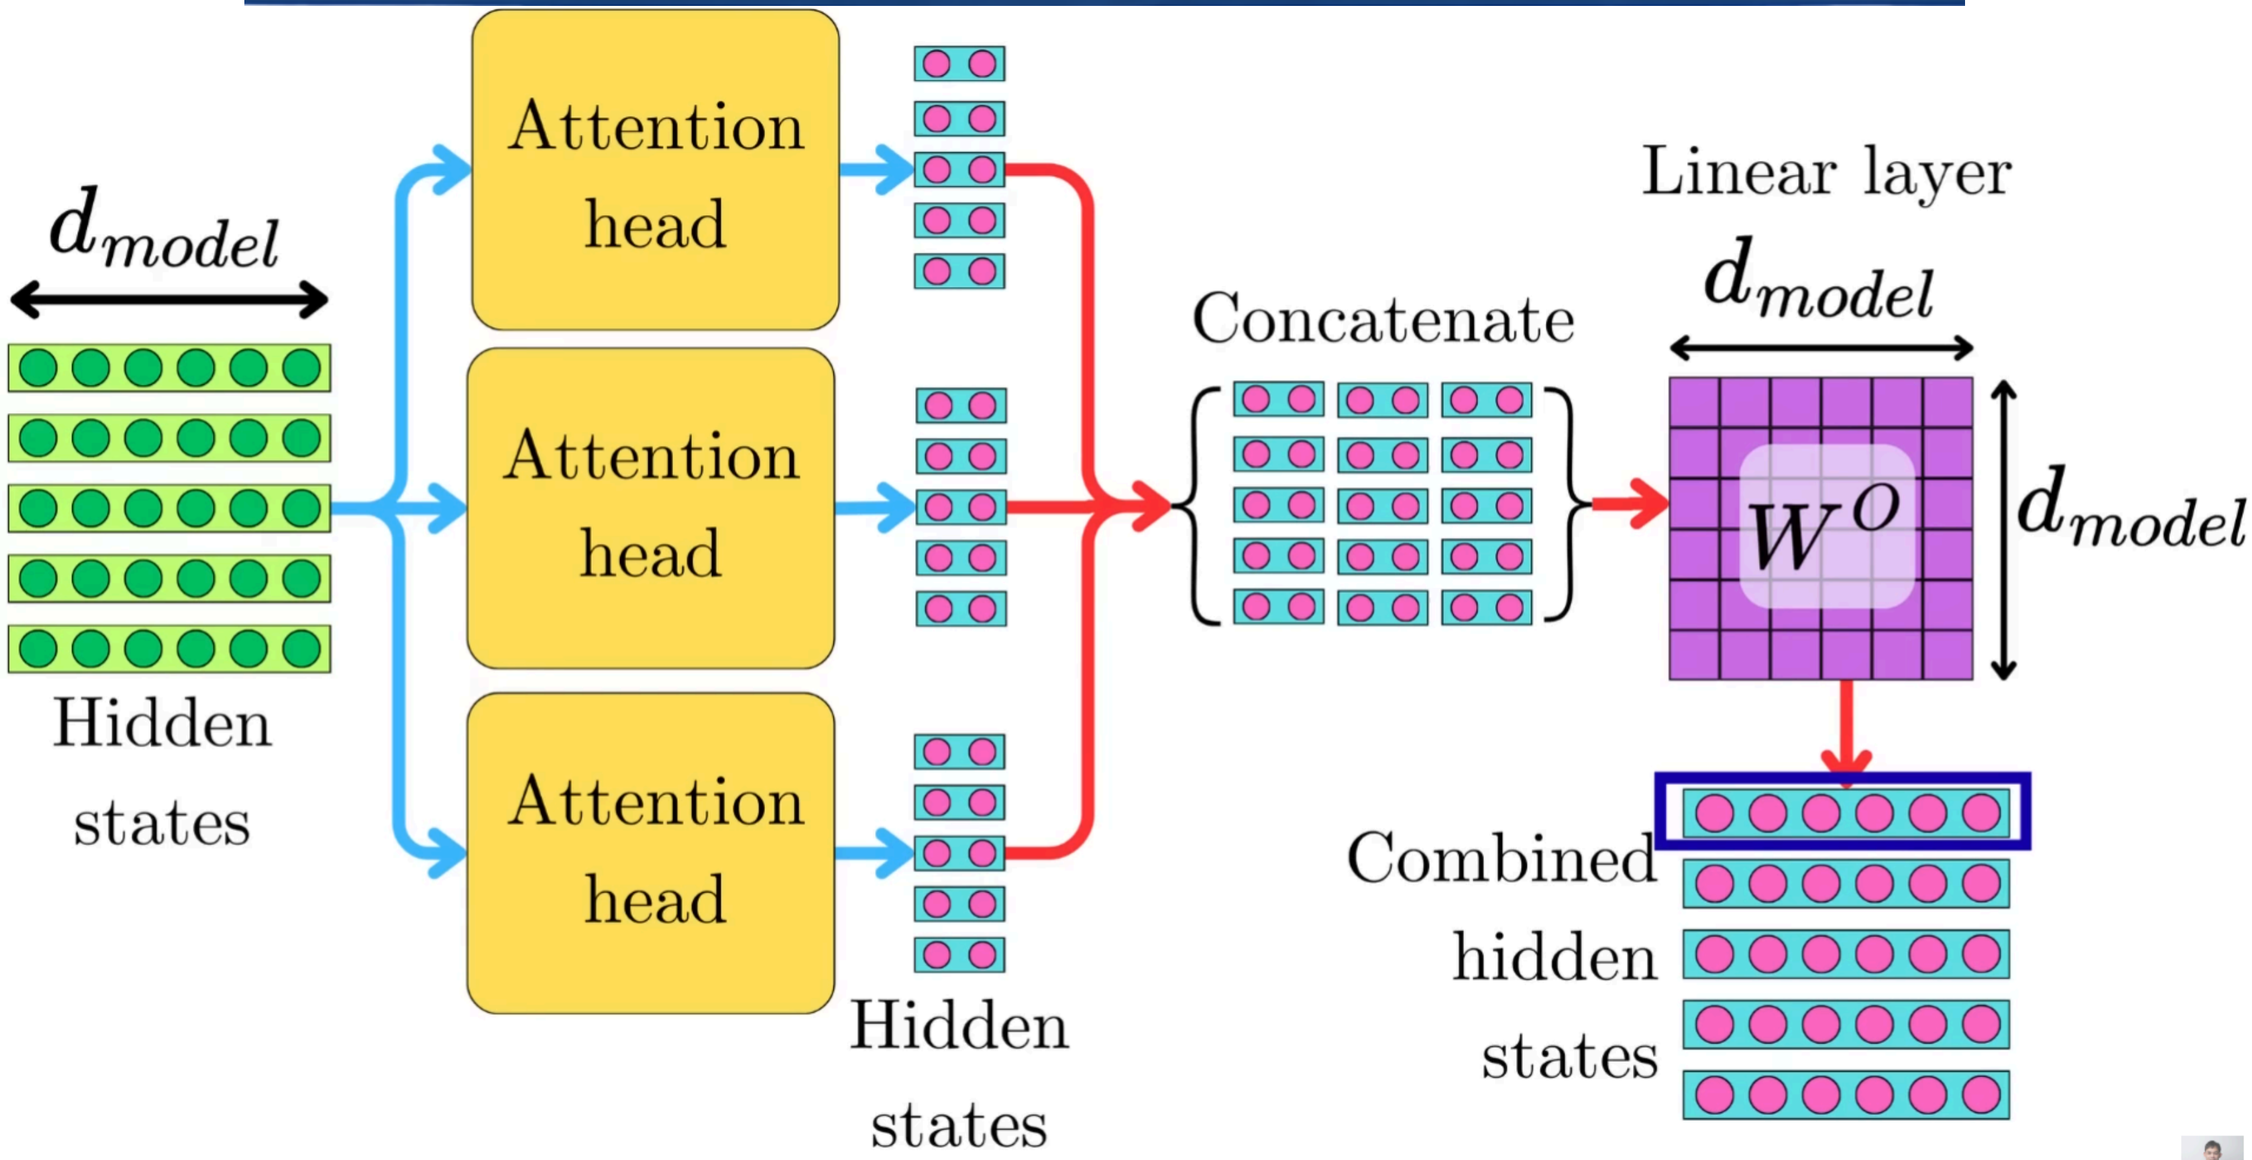

Feed Forward Network (FFN)

FFN là gì?

- Mạng Neural Network truyền thẳng, đặt sau Multi-Head Self-Attention.
- Biến đổi biểu diễn của từng token qua 2 lớp Linear và ReLU.

Cấu trúc

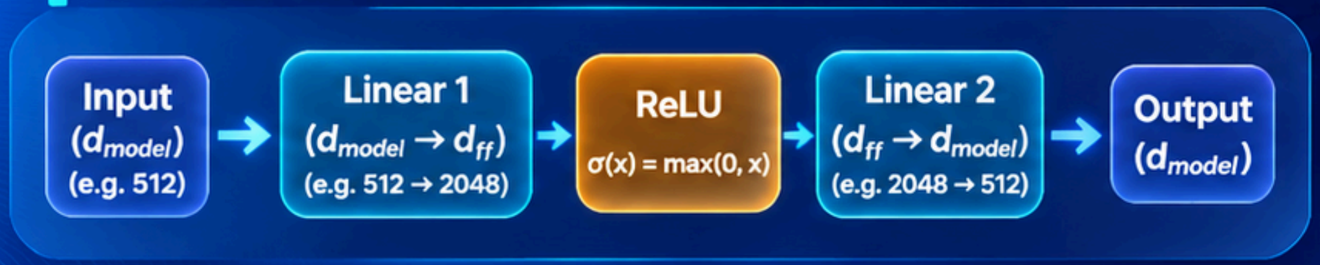

→ **FFN giúp mô hình học các phép biến đổi phi tuyến phức tạp hơn sau khi đã tổng hợp thông tin giữa các token.**

Masked Multi-Head Self-Attention & Cross-Attention

Masked Multi-Head Self-Attention

- Giống Self-Attention nhưng thêm **Mask** để ngăn nhìn thấy token tương lai.
- Giúp Decoder chỉ dùng thông tin đã có trước đó.

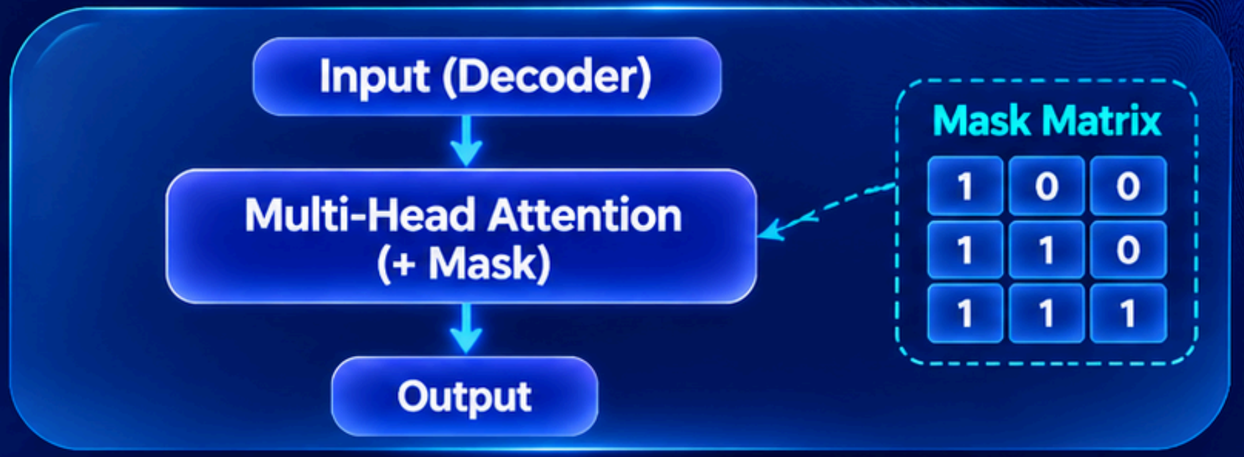

Cross-Attention

- Cho phép Decoder tham chiếu thông tin từ **Encoder Output**.
- Query từ Decoder, Key & Value từ Encoder.

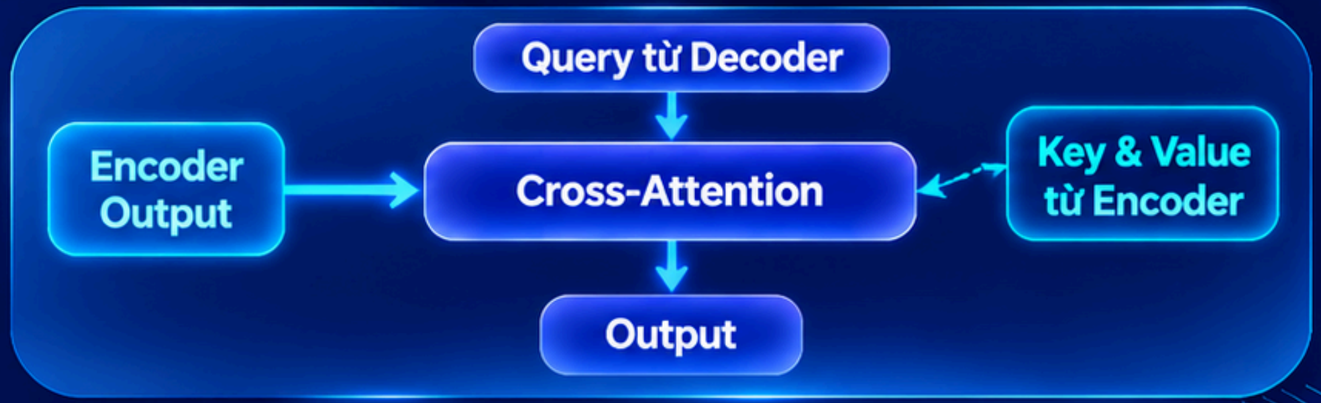

→ **Masked Self-Attention giúp Decoder tự nhìn lại quá khứ, còn Cross-Attention giúp kết nối với Encoder.**

So sánh Encoder Block & Decoder Block

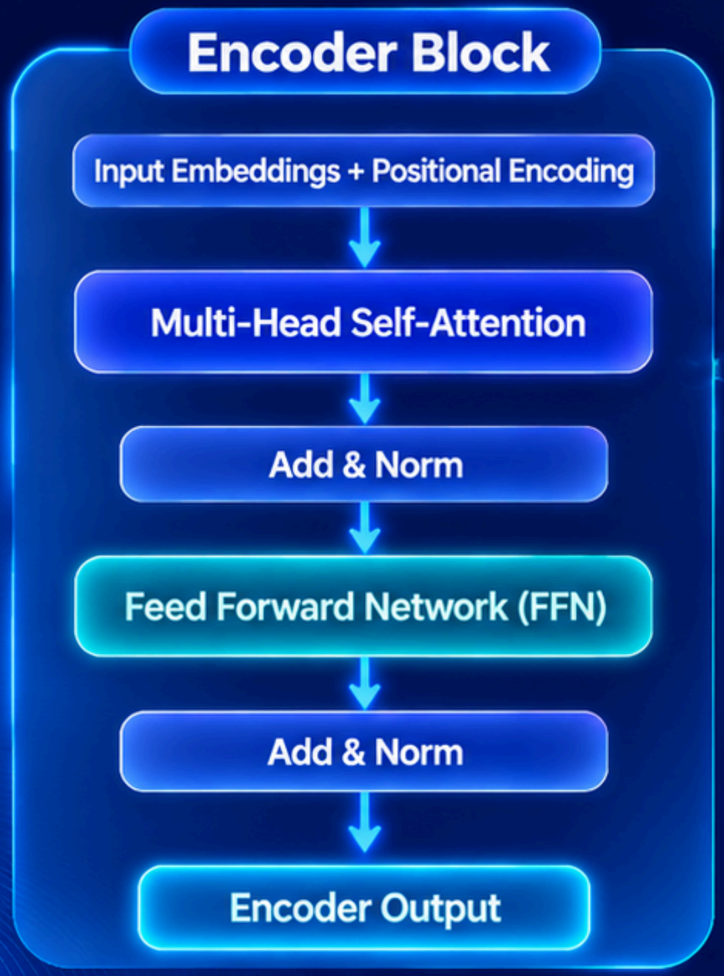

Tiêu chí	Encoder Block	Decoder Block
Self-Attention đầu tiên	Multi-Head Self-Attention	Masked Multi-Head Self-Attention
Attention thứ hai	Không có	Cross-Attention
FFN	Có	Có
Thứ tự chính	SA → FFN	Mask SA → Cross-Attn → FFN
Mục tiêu	Mã hóa, xây dựng biểu diễn ngữ cảnh	Sinh chuỗi đầu ra dựa trên Encoder
Đầu vào	Câu nguồn	Câu đích (dịch/ sinh)
Đầu ra	Biểu diễn ngữ cảnh	Chuỗi token đầu ra

→ **Encoder tạo biểu diễn ngữ cảnh, Decoder sử dụng biểu diễn đó để sinh ra chuỗi đầu ra chính xác.**

7. CÁC DẠNG TRANSFORMER

7.1 Encoder-only

Chỉ dùng khối Encoder, mạnh về hiểu văn bản

Self-attention hai chiều: mỗi token nhìn cả bên trái và bên phải.
Đầu ra là vector ngữ cảnh cho từng token.
Huấn luyện bằng Masked Language Modeling (che token rồi dự đoán).
Không có cơ chế sinh tuần tự nên không sinh văn bản tự nhiên.

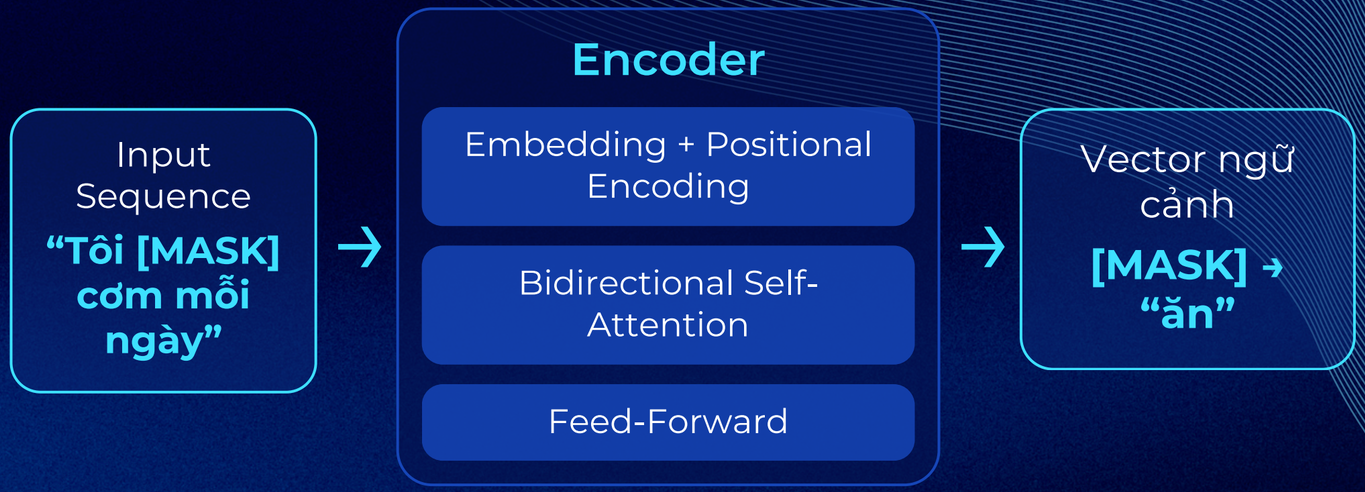

[MASK] nhìn cả “Tôi” (bên trái) và “cơm mỗi ngày” (bên phải) để đoán ra “ăn”.

Tiêu biểu: BERT, RoBERTa. Dùng cho phân loại, NER (Named Entity Recognition), QA (Question Answering)

7.2 Decoder-only

Chỉ dùng khối Decoder, mạnh về sinh văn bản

Masked self-attention (causal): vị trí *t* không nhìn thấy vị trí sau *t*
Bỏ cross-attention, chỉ giữ masked self-attention và Feed-Forward.
Huấn luyện bằng dự đoán token kế tiếp (autoregressive).
Sinh từng token một, đơn giản và dễ scale.

Token “Việt” được nối vào prompt, mô hình lặp lại để dự đoán token tiếp theo là “Nam”.

Tiêu biểu: GPT, LLaMA, nền của hầu hết LLM hiện nay.

7.3 Encoder–Decoder

Kết hợp cả hai khối, chuyển chuỗi nguồn thành chuỗi đích

- Encoder đọc toàn bộ input và tạo biểu diễn ngữ cảnh.
- Decoder sinh output, dùng **cross-attention** (Q từ decoder, K/V từ encoder).
- Phù hợp khi input và output là hai chuỗi khác nhau.
- Huấn luyện kiểu seq2seq (dịch, span corruption).

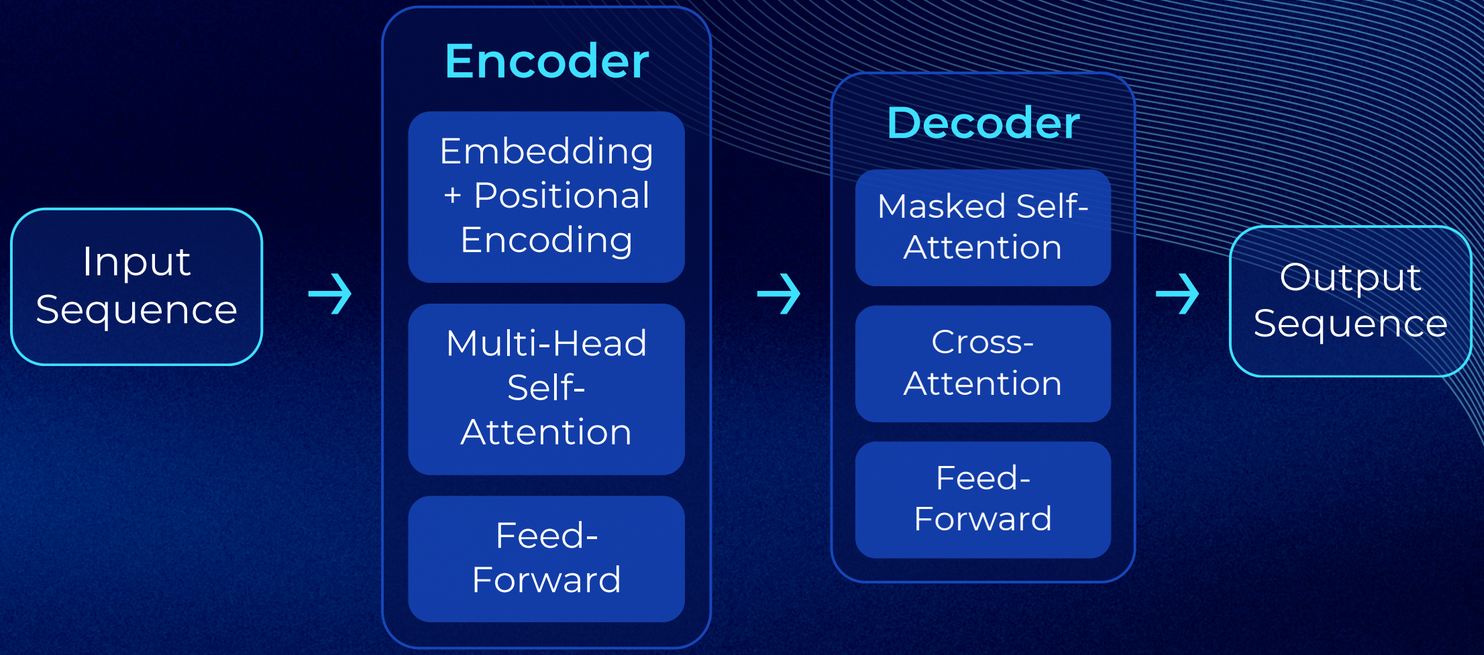

Ví dụ: “translate English to German: That is good.” → “Das ist gut.”

Decoder sinh từng từ và dùng cross-attention để nhìn lại toàn bộ câu input.

Tiêu biểu: T5, BART, Transformer gốc (Vaswani, 2017).

BERT, GPT, T5: kiến trúc và tác vụ

So sánh kiến trúc, cơ chế attention và tác vụ

TIÊU CHÍ	BERT	GPT	T5
Dạng kiến trúc	Encoder-only	Decoder-only	Encoder–Decoder
Attention	Hai chiều	Một chiều (causal)	Encoder: hai chiều Decoder: causal
Cross-attention	Không	Không	Có, tới Encoder
Tác vụ phù hợp	Phân loại, NER, QA trích xuất	Chatbot, sinh văn bản, sinh mã lập trình	Dịch máy, tóm tắt, QA text-to-text
Cách sử dụng	Thêm đầu tác vụ rồi fine-tune	Prompting, few-shot; cũng có thể fine-tune	Text-to-text; prompting hoặc fine-tune theo tác vụ

What's Next

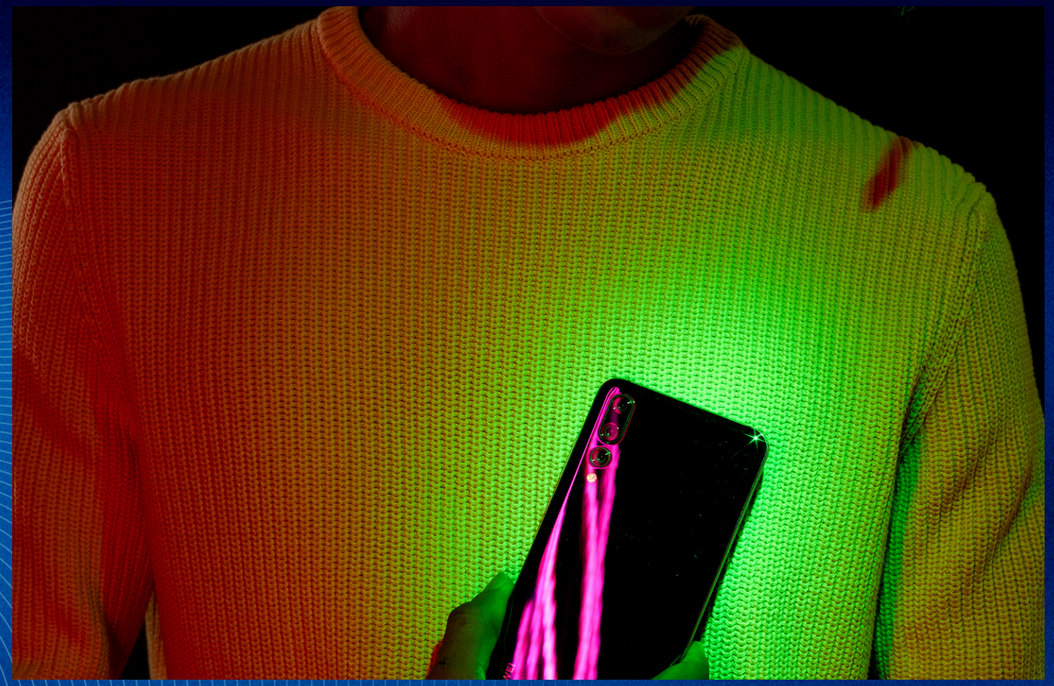

Our upcoming roadmap includes major product updates, expansion into new industries, and enhanced AI-driven features. We are also focused on improving integration with existing business tools to maximize adoption. Each step is designed to grow our user base and expand market reach.

Driving Adoption

Businesses and individuals face inefficiencies caused by outdated systems, fragmented tools, and rising operational costs. Current solutions often fail to adapt to the speed of modern demand, leaving organizations struggling to keep up. The result is wasted time, reduced productivity, and limited opportunities for growth.

The People Behind the Vision

Our team is made up of experienced professionals who bring expertise in technology, business strategy, and product development. Together, we combine technical excellence with business insight to deliver a solution that works. Passion, innovation, and execution are at the heart of everything we do.

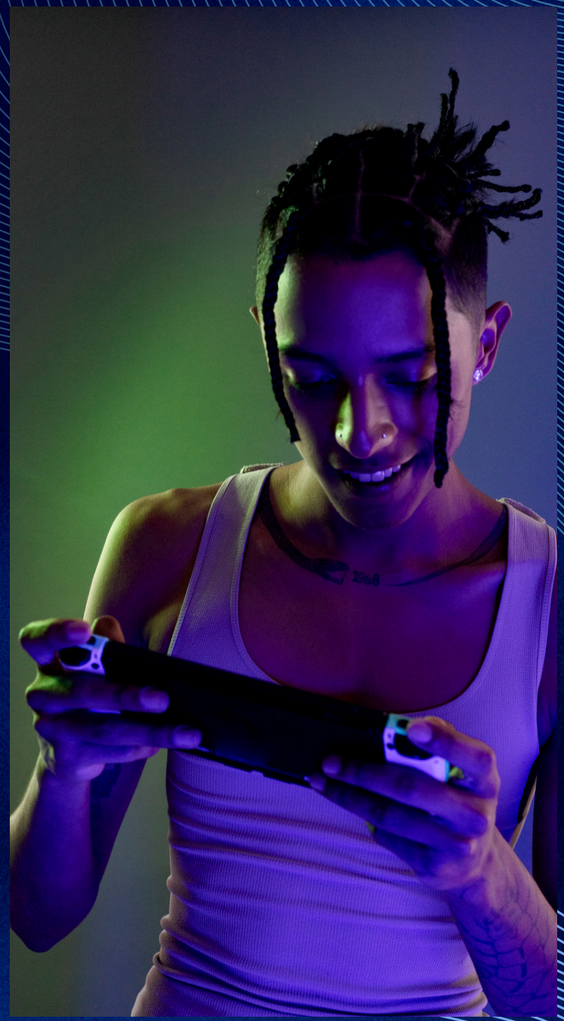

The People Behind the Vision

Our team is made up of experienced professionals who bring expertise in technology, business strategy, and product development. Together, we combine technical excellence with business insight to deliver a solution that works. Passion, innovation, and execution are at the heart of everything we do.

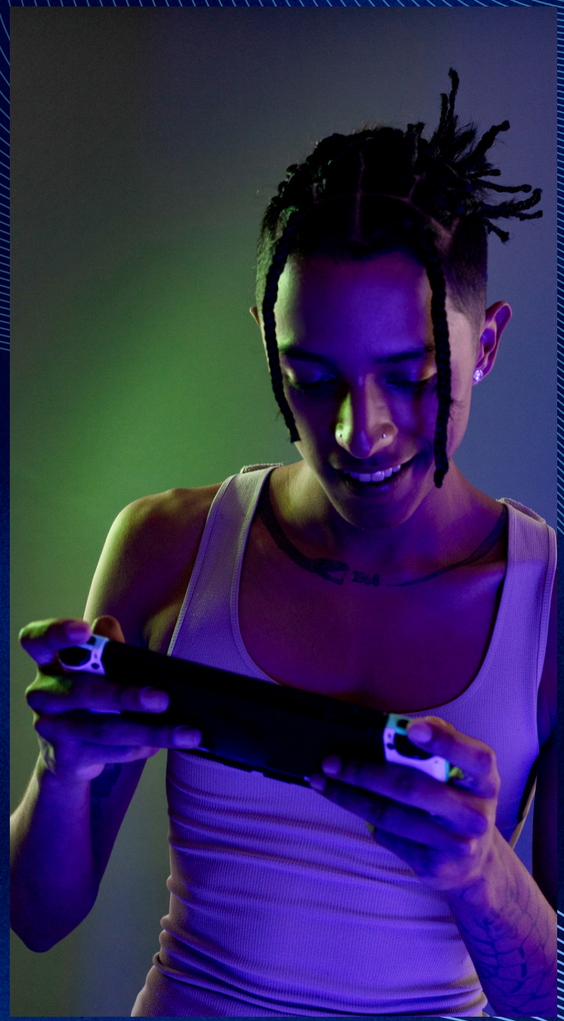

Collaborating for Impact

We believe growth comes from collaboration. That’s why we have established alliances with key players in technology, distribution, and customer engagement. These partnerships not only expand our reach but also strengthen the value of our offering for end users.

Sustainable Growth Ahead

Based on current traction and market demand, our financial projections show strong growth in revenue, user adoption, and profitability over the next three to five years. These forecasts reflect both conservative assumptions and scalable opportunities that will drive long-term success.

Why Partner With Us

This is an opportunity to invest in a high-potential solution at the right stage. With proven traction, a scalable business model, and growing demand, we offer a strong return potential.

By partnering with us, you are not just investing in technology—you are investing in the future.

Why Partner With Us

This is an opportunity to invest in a high-potential solution at the right stage. With proven traction, a scalable business model, and growing demand, we offer a strong return potential.

By partnering with us, you are not just investing in technology—you are investing in the future.

Shaping the Future Together

Technology has the power to change lives and industries. With your support, we can expand our impact, accelerate adoption, and drive innovation forward. Let’s shape the future of technology together—today.

www.reallygreatsite.com

hello@reallygreatsite.com

123 Anywhere St., Any City, ST 12345

+123-456-7890